ファインチューニング手法に基づく被災建物画像の多クラス損傷度分類の精度改善

山田悠人
東京理科大学 創域理工学部

TOKYO UNIVERSITY OF SCIENCE since 1881

創域理工学部
Faculty of Science and Technology

松田研究室
MATSUDA LAB.

研究背景

日本では地震や津波による被害が大きい

- 日本はM6.0以上の地震は年間平均で約16回発生
- 地震と津波が同時に発生するケースがある
- 災害直後の被害調査は被災地支援や今後の防災対策に不可欠

大規模災害時の建物被害評価の課題

- 専門家による目視判定に依存
- 膨大な人手と時間を要する

→ 画像を自動分類したい！！

https://www.data.jma.go.jp/eqev/data/gaikyo/monthly/202412/202412nen_nihon_jishin.pdf

画像分類による建物被害評価

能登半島地震で収集した建物被害画像を6classに自動分類
正解クラスは専門家が判別したデータセット

クラス	被害要因	被害度合い	主な特徴	画像数
地震大	地震	大	倒壊、生命に危機	313
地震中	地震	中	構造の破損、柱の傾斜	112
地震小	地震	小	非構造材のひび割れ、軽微な損傷	98
津波大	津波	大	津波による消失部分あり	88
津波小	津波	小	1階までの浸水構造は維持	126
被害なし	-	なし	被害が確認できない	303

災害画像データセット（1/2）

(1)地震大

(2)地震中

(3)地震小

災害画像データセット（2/2）

(4)津波大

(5)津波小

(6)被害なし

先行研究とその課題

先行研究

- 地震（大・中・小）、津波（大・小）、被害なしの6クラス分類により損傷度と原因を同時に推定
- 画像分類タスクに実績のある**ResNet50**をファインチューニングして利用

先行研究の課題

- 従来のファインチューニング手法は全パラメータの更新を要するため、過学習のリスクが高い
- ResNet50は精度の限界が存在

鈴木 海友， 他，“被災家屋画像から被害度や種類を分類す るシステムの構築”，ソフトウェア・シンポジウム論文集， pp.39–45, June 2025.

本研究の目的

以下の工夫による分類精度の向上を目的とする

- ファインチューニング手法（LoRA)の導入
  - 少量データセットにおけるLoRAの有効性検証と実用的な応用
- 最新のモデルアーキテクチャの導入
  - CNN系とTransformer系モデルの性能比較による最適アーキテクチャの探索
  - 既存の事前学習済みモデルをベースに、
    少量の被災建物画像データでも高精度な分類の実現

ファインチューニング手法の動向

従来のファインチューニング手法はモデル全体のパラメータを更新するため、
訓練データが少ない状況下では過学習が生じやすい

Low-Rank Adaptation (LoRA)

- **重み行列を低ランク分解**し、元のモデルパラメータを固定したまま
  低ランク分解された行列のみを更新することで、**効率的な転移学習**を実現する手法
- **少量の訓練データでも高い性能**が得られることが示されている

E. Hu, et al., “LoRA: Low-Rank Adaptation of Large Language Models”, International Conference on Learning Representations (ICLR), Apr. 2022.

関連研究

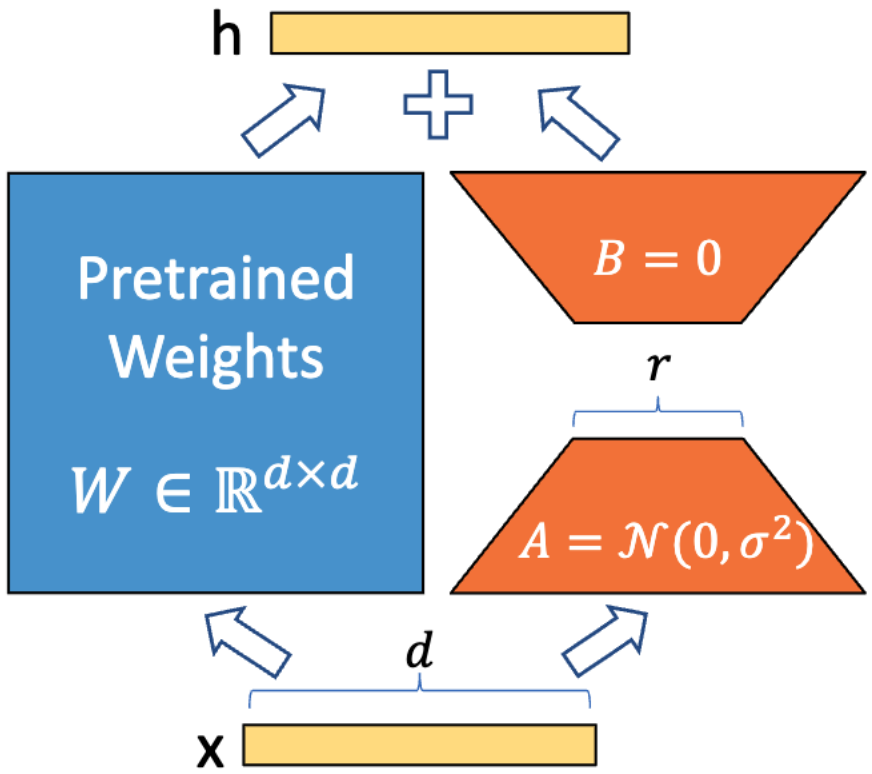

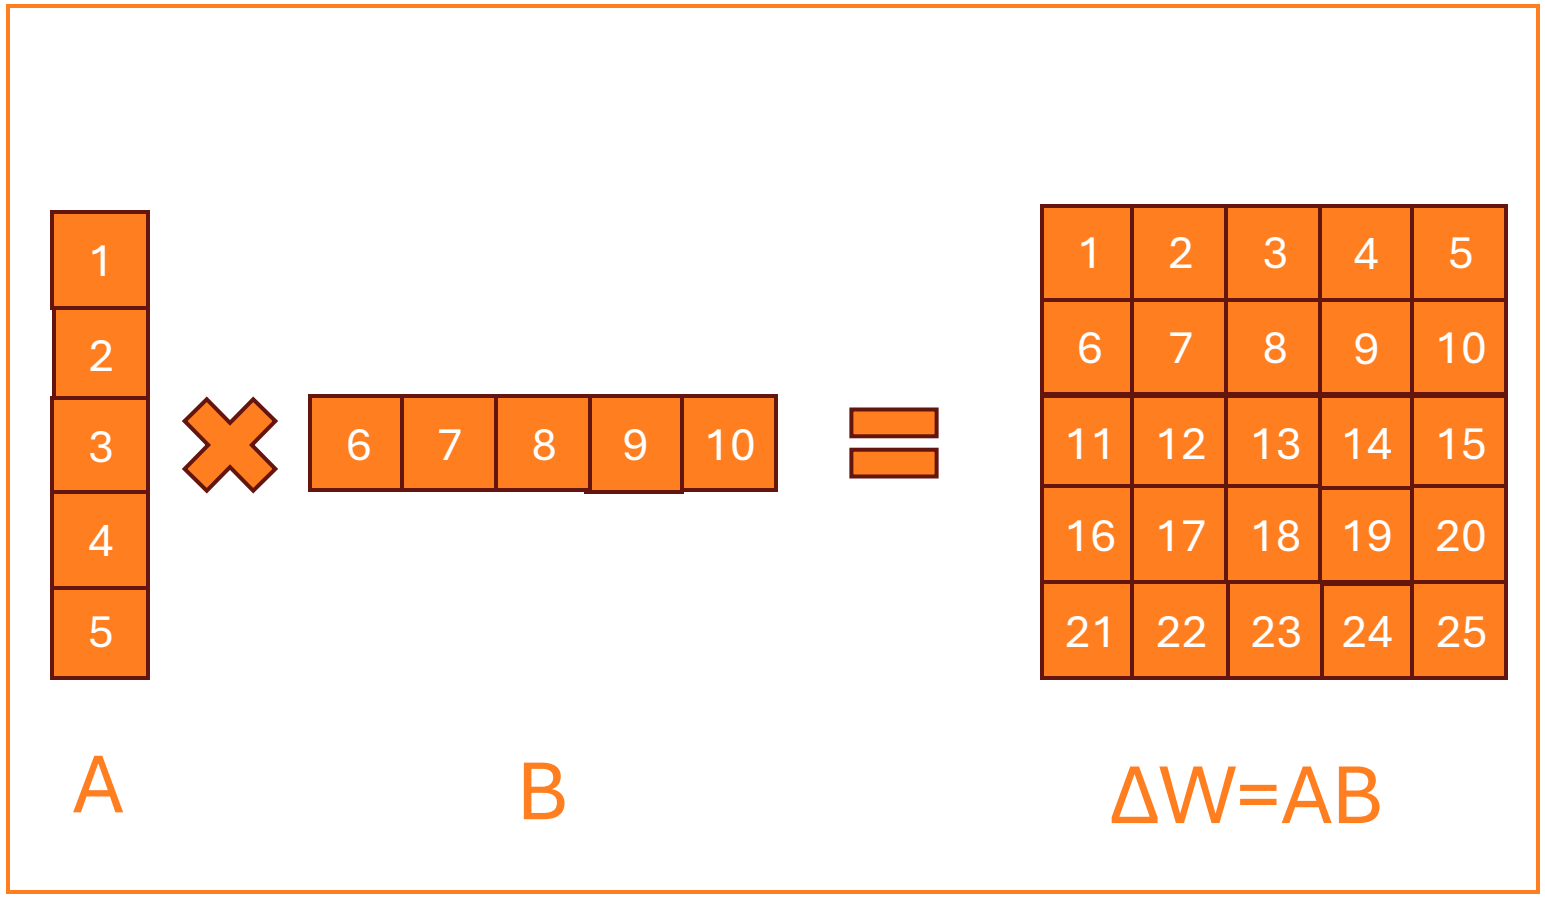

E. Hu, et al., “LoRA: Low-Rank Adaptation of Large Language Models”, International Conference on Learning Representations (ICLR), Apr. 2022.

比較検証モデル：アーキテクチャの選定

CNN系モデル

ConvNeXt

- 最新のCNNアーキテクチャ
- ViTの設計思想を取り入れた高性能モデル

EfficientNetV2

- 計算効率と精度のバランスを最適化したモデル。モバイルデバイスにも適用可能

ResNet（先行研究モデル）

- 残差接続を導入した50層CNN
- 勾配消失問題を解決し、深層学習を可能に

Transformer系モデル

DINO

- 自己教師あり学習で事前学習されたViTベースのモデル
- ラベルなしデータからの特徴抽出に優れる

Swin-Transfomer

- 階層的なTransformerモデル
- シフトウィンドウ機構により効率的な計算を実現

ViT

- 画像をパッチに分割し、自己注意機構で大域的な特徴を捉える基本的なVisio Transformer

代表的なモデル**の比較により、**
被災建物画像分類に最適なアーキテクチャを探索

実験設定

前処理

データ拡張
ランダムな回転、反転、拡大縮小、明度調整

データ分割
訓練：検証 = 8:2 の比率で分割

学習パラメータ設定

バッチサイズ
8, 16, 32の範囲で探索

エポック数
30（固定）

最適化手法
標準FT: Adam / LoRA: AdamW

損失関数
重み付きクロスエントロピー損失

評価指標

Accuracy

全予測のうち正しく分類された割合
全体的な性能を把握するための基本指標

多クラス分類における評価の難しさ

6クラス分類では単一指標だけでなく、
複数の評価指標を組み合わせて
総合的に性能を判断することが重要

Weighted F1-score

各クラスのサンプル数で重み付けした
F1スコア
クラス不均衡データセットでの総合評価
に有効

Macro F1-score

各クラスのF1スコアの単純平均
少数クラスの性能も均等に評価

実験結果：標準ファインチューニングの性能評価

モデル名	Accuracy	weighted F1	macro F1
ConvNext-Tiny	0.66	0.63	0.54
ConvNext-Base	0.64	0.63	0.53
EfficientNetV2-S	0.40	0.42	0.38
ResNet-50 （先行研究モデル）	0.51	0.53	0.46
DiNOv2	0.45	0.43	0.37
Swin-Tiny	0.62	0.59	0.50
Vit-Base	0.63	0.63	0.54

実験結果：LoRA適用による性能向上

モデル名	Accuracy	weighted F1	macro F1
ConvNext-Tiny	0.64	0.64	0.58
ConvNext-Base	0.66	0.64	0.56
EfficientNetV2-S	0.18	0.19	0.16
ResNet-50 （先行研究モデル）	0.45	0.45	0.37
DiNOv2	0.65	0.65	0.56
Swin-Tiny	0.47	0.50	0.46
Vit-Base	0.49	0.51	0.44

実験結果：LoRA適用による性能向上

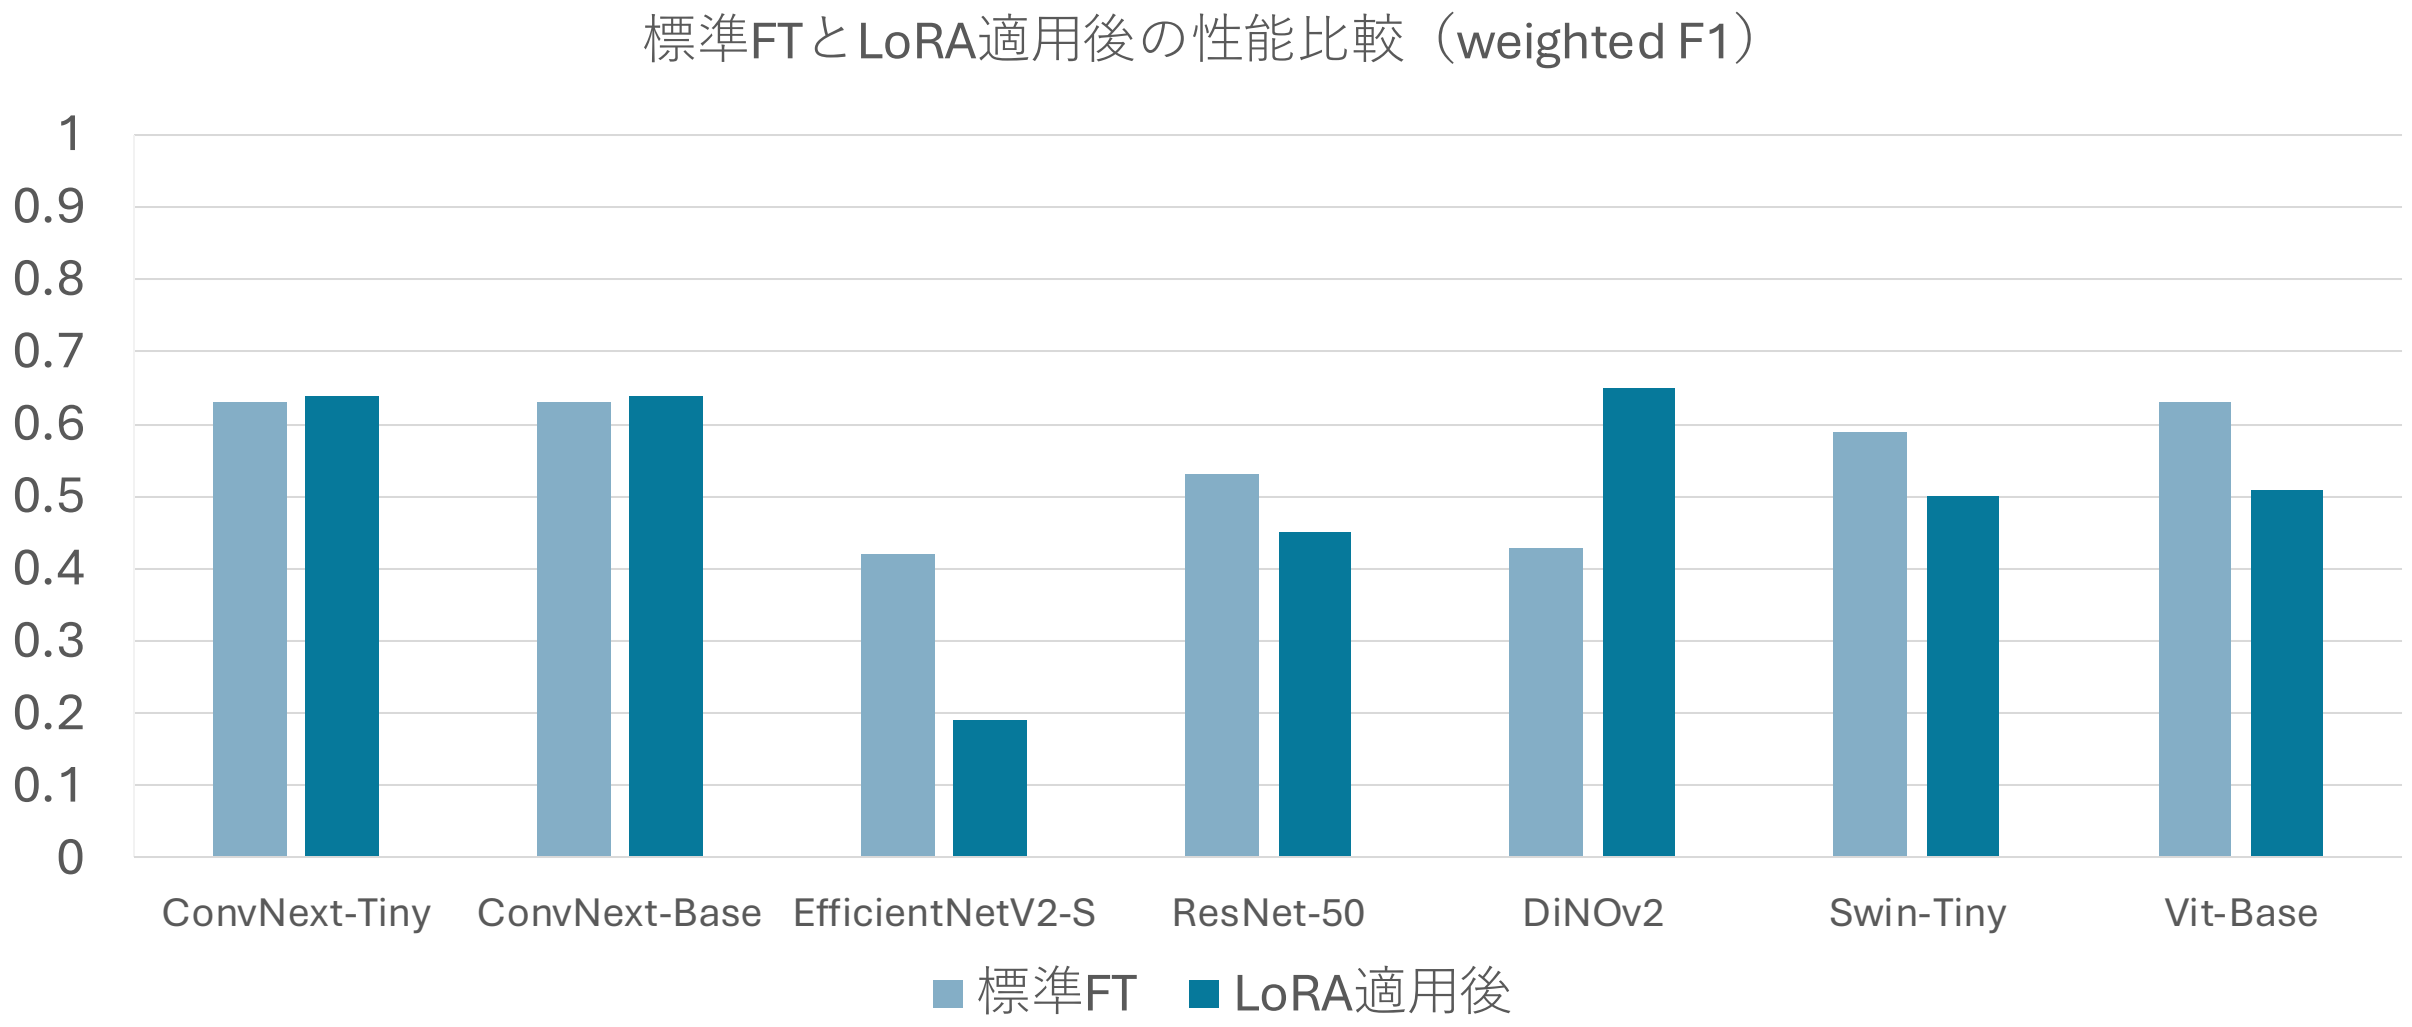

考察

モデルアーキテクチャとLoRAの有効性

Transformer系モデルとLoRAの相性

- 自己注意機構に多数の線形変換が含まれるため、LoRA適用の効果が大きい
- Dinov2のように大規模事前学習された表現を、少ないパラメータで被災家屋に特化できる

CNN系モデルの特性

- ConvNeXtは標準FTで高性能を発揮
- しかしLoRAの適用余地は限定的で、改善効果は小さい

今後の課題

ノイズの影響と除去の重要性

- 被災建物画像には周辺環境（他の建物、樹木など）のノイズが多く含まれる
- 前処理段階でのノイズ除去や建物領域の抽出が精度向上につながる可能性

データセット拡充の必要性

- 特に津波被害のデータが少なく、より多様な被災状況のデータ収集が必要
- データ拡張の検討

まとめ

- 目的：被災建物画像の自動分類の精度向上
- 提案：Vision Transformer/DINOv2などのモデルの検討
- 実験結果：
  - ResNet-50
    - 正答率/Weighted F1：0.51/0.53
  - Dinov2+LoRA
    - 正答率/Weighted F1：0.65/0.65
- 今後の課題：
  - ノイズの除去
  - データセット拡充

謝辞

本研究は、東京理科大学マルチハザード都市防災研究拠点の
ご支援を受けて行われました。

ご協力いただいた関係機関の皆様に深く感謝いたします。