被災建物画像の多クラス損傷度分類における マルチタスク学習の有効性

Effectiveness of Multi-Task Learning
for Multi-Class Damage Severity Classification of Disaster-Affected Building Images

山田 悠人 Yuto Yamada　鈴木 海友 Kaiyu Suzuki　松田 一朗 Ichiro Matsuda　多賀 祥平 Shohei Taga　松澤 智史 Tomofumi Matsuzawa　二瓶 泰雄 Yasuo Nihei　柏田 仁 Jin Kashiwada

東京理科大学 創域理工学部
Faculty of Science and Technology, Tokyo University of Science

1　まえがき

大規模災害時の迅速な被害評価において，被災建物画像の損傷度自動分類は重要である．しかし，実データでは深刻な被害クラスほどサンプル数が少ないクラス不均衡問題が生じ，一部のクラスでデータが著しく不足する．また，損傷度ラベルは災害種別（地震・津波）や被害程度（大・中・小）といった階層構造を有するが，従来の単一タスク分類 [1] ではこれを活用できていない．

本研究では，筆者らの先行研究 [1] で採用された自己教師あり事前学習モデル DINOv2[2] および LoRA[3] を基盤とし，ラベルの階層構造を活用する補助タスク（被害程度・災害種別・被害検出）を導入したマルチタスク学習 [4] を提案する．さらに，能登半島地震による被災建物の画像を用いた実験により，本手法の有効性を示す．

2　提案手法

データセット　筆者らが収集した 2024 年能登半島地震後の被災建物画像 1,040 枚（各 518×518 画素）を使用する．各画像は 6 クラス（被害なし，地震大・中・小，津波大・小）に分類されており，データセット全体を訓練 80%・検証 20%に分割する．

マルチタスク学習　筆者らの先行研究 [1] で採用した DINOv2 （ViT-L/14）および LoRA （低ランク次元 $r = 16$，スケーリング係数 $\alpha = 16$）を基盤とし，ラベルの階層構造を活用するため，主タスク（6 クラス分類）に加えて 3 つの補助タスクを導入する．図 1 に示すように，補助タスクは，被害程度（小・中・大の 3 クラス），災害種別（地震・津波の 2 クラス），被害検出（有・無の 2 クラス）であり，これらの正解ラベルは主タスクのラベルから自動的に派生させる．

学習設定　主タスクの損失 L_{main} に対し，3 つの補助タスク（被害程度･災害種別･被害検出）の損失 $L_{\text{sub},i}$ をそれぞれ重み $w_i \in \{0.2, 0.2, 0.3\}$ で重み付け加算した合計損失 $L = L_{\text{main}} + \sum_{i=1}^{3} w_i L_{\text{sub},i}$ を用いて学習を行う．クラス不均衡には PyTorch の WeightedRandomSampler で対処し，最適化手法は AdamW（学習率 3×10^{-5}），エポック数 30 として 10 種類の乱数シードで評価する．

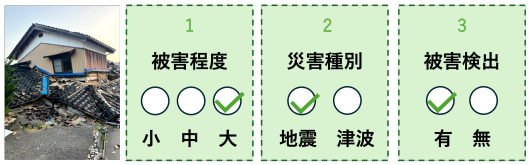

図 1: 3 種類の補助タスク

表 1: 性能比較（10 シード平均 ± 標準偏差）

手法	Accuracy (%)	Macro F1
Baseline [1]	68.99 ± 2.95	0.6366 ± 0.0272
Multi-task	**71.04 ± 3.10**	**0.6556 ± 0.0488**

3　実験結果

表 1 に性能比較を示す．10 シードでの評価の結果，提案手法（Multi-task）は Macro F1 で平均 0.6556 を達成し，Baseline （0.6366）に対して+1.90%pt の改善を示した．Accuracy についても Baseline の 68.99%に対して 71.04%と，+2.05%pt の改善が見られた．

4　考察とまとめ

Macro F1 の改善幅が大きいことは，少数クラスでの性能向上を示唆する．これは，補助タスクの導入により，サンプル数の少ない深刻な被害クラスが複数のタスクで共通して学習されるためと考えられる．例えば,「地震大」のサンプルは主タスクだけでなく,「被害あり」「被害程度：大」「災害種別：地震」という補助タスクでも学習対象となり，実質的な学習機会が増加する [4]．この効果により，クラス不均衡下において少数クラスに対する頑健な特徴表現を獲得できたと考えられる．また，災害種別や被害検出といった補助タスクが，モデルの注意を損傷評価に重要な構造的特徴へ集中させる役割を果たしたと推察される．

本研究では補助タスクの損失重みを実験的に固定値（0.2, 0.2, 0.3）で与えたが，学習の進行に応じて各タスクの収束速度は異なっていた．そのため，学習段階やタスクごとの損失値に基づいて重みを動的に制御することで，主タスクと補助タスクのバランスを調整することが可能となり，さらなる性能向上が期待できる．

本研究は，東京理科大学マルチハザード都市防災研究拠点の支援を受けた．

参考文献

[1] 山田, 他：“ファインチューニング手法に基づく被災建物画像の多クラス損傷度分類の精度改善”, 第 24 回情報科学技術フォーラム (FIT 2025), 第 3 巻, pp. 339–340 (2025).

[2] M. Oquab, et al.: “DINOv2: Learning robust visual features without supervision”, Transactions on Machine Learning Research (2024).

[3] E. J. Hu, et al.: “LoRA: Low-rank adaptation of large language models”, International Conference on Learning Representations (ICLR 2022), pp. 1–13 (2022).

[4] S. Ruder: “An overview of multi-task learning in deep neural networks”, arXiv preprint arXiv:1706.05098, pp. 1–14 (2017).