

被災建物画像の 多クラス損傷度分類における マルチタスク学習の有効性

山田悠人

東京理科大学 創域理工学部



研究背景

大規模災害時の建物被害評価

- 日本では地震や津波による被害が多い
- 防災や復興のため被害状況の把握が重要

課題

- 目視判定は膨大な人手と時間を要するため自動化が検討されている

目的

- 被災建物画像の多クラス損傷度分類の精度向上を目指す



能登半島地震の被害調査より

建物被害評価のデータセット

能登半島地震で収集した建物被害画像1,040枚（518×518画素）
正解クラスは専門家が**被害要因**と**被害度合い**に応じて6通りに分類

被害度合い				
被害要因	大	中	小	なし
地震	313	112	98	303
津波	88	-	126	

災害画像データセット (1/2)



(1)地震大

倒壊、生命に危機



(2)地震中

柱の傾斜、構造の破損



(3)地震小

非構造材のひび割れ、
軽微な損傷

災害画像データセット (2/2)



(4)津波大

津波による
消失部分あり



(5)津波小

1階までの浸水
構造は維持



(6)被害なし

被害が確認できない

建物被害評価のデータセット

能登半島地震で収集した建物被害画像1,040枚（518×518画素）
正解クラスは専門家が**被害要因**と**被害度合い**に応じて6通りに分類

被害度合い				
被害要因	大	中	小	なし
地震	313	112	98	303
津波	88	-	126	

筆者らによる先行研究[1]（ベースライン）

- 自己教師あり事前学習モデル DINOv2[2] を基盤として採用
- LoRA[3]による効率的なファインチューニングを実施
- 被災建物画像を**6クラス分類**するモデルを学習

6クラス分類タスクの構造



先行研究の課題

- ① クラス間のデータ数が不均衡であり、少数クラスの精度が低下する
- ② ラベルの階層構造（被害要因・被害度合い）を活用できていない

[1] Y. Yamada, et al., "ファインチューニング手法に基づく被災建物画像の多クラス損傷度分類の精度改善", Forum on Information Technology (FIT2025), 2025.

[2] M. Oquab, et al., "DINOv2: Learning Robust Visual Features without Supervision", Transactions on Machine Learning Research, 2024.


[3] E. J. Hu, et al., "LoRA: Low-Rank Adaptation of Large Language Models", International Conference on Learning Representations (ICLR), 2022.

提案手法：マルチタスク学習の導入

マルチタスク学習[4]とは

- メインのタスクとは別に関連タスク複数設定
- それぞれのタスクの損失の加重和で共通特徴抽出器を学習

マルチタスク学習の概念図



➤ 特徴抽出器を共通にすることで、汎化性能の向上が期待できる（正則化効果）

[4] S. Ruder, "An Overview of Multi-Task Learning in Deep Neural Networks", arXiv:1706.05098, 2017.

提案手法：3つの補助タスクの導入

補助タスク1

被害程度

被害レベルを識別



小 中 大

補助タスク2

災害種別

災害の種類を識別




地震 津波

補助タスク3

被害検出

被害の有無



有 無



1	2	3
被害程度	災害種別	被害検出
☐ ☐ ☒	☒ ☐	☒ ☐
小 中 大	地震 津波	有 無




1	2	3
被害程度	災害種別	被害検出
☐ ☐ ☐	☐ ☐	☐ ☒
小 中 大	地震 津波	有 無

メインタスク（6クラス）の正解ラベル



3つの補助タスクのラベルを自動的に派生

提案手法:モデル構造と損失関数



損失の計算

$$L = L_{main} + 0.2 \times L_{level} + 0.2 \times L_{category} + 0.3 \times L_{detect}$$

実験設定

モデルと学習方法

DINOv2 (ViT-L/14)
LoRA

データ分割

訓練 80% / 検証 20%

不均衡対策

Weighted Random Sampler
により少数クラスのサンプリング頻度を調整

損失の重み

$w_1=0.2$ (被害程度)
 $w_2=0.2$ (災害種別)
 $w_3=0.3$ (被害検出)

評価方法


乱数シードを変えて10回評価
Accuracy および Macro F1の平均値と標準偏差を算出

※ Weighted Random Sampler はベースラインでも同様に使用

実験結果

手法	Accuracy (%)	Macro F1
シングルタスク (Baseline)	68.99 ± 2.95	0.6366 ± 0.0272
Multi-task (提案手法)	71.04 ± 3.10	0.6556 ± 0.0488

混合行列による性能比較



提案手法により、
少数クラスのRecallが改善

考察

判定を誤った例について調査

問題は判定基準の不一致？

専門家の判定基準

建物の構造的安全性を基準

モデルが捉えるもの

建物周りの周辺コンテキスト

判定基準の乖離が
誤分類を生む

解決策

建物ROI抽出 → 周辺コンテキストの影響を除去

正解：地震小
予測：被害なし



正解：被害なし
予測：地震小



まとめ

目的

- 被災建物画像の6クラス分類の精度向上

提案

- ラベルの階層構造を活用したマルチタスク学習の導入

結果

- Accuracy: 68.99% → 71.04% (+2.05%pt)
- Macro F1: 0.6366 → 0.6556 (+1.90%pt)

示唆

- 少数クラスの識別能力向上
- 補助タスクによる正則化効果

本研究は、東京理科大学マルチハザード都市防災研究拠点のご支援を受けて行われました。
ご協力いただいた関係機関の皆様に深く感謝いたします。