

視覚基盤モデルによる小・中規模被災建物画像データセットの分類性能の比較

Comparison of Classification Performance Using Visual Foundation Models for Small- and Medium-Scale Datasets of Disaster-Damaged Buildings

山田 悠人[†]
Yuto YAMADA[†]

鈴木 海友[†]
Kaiyu SUZUKI[†]

松田 一朗[†]
Ichiro MATSUDA[†]
柏田 仁[‡]
Jin KASHIWADA[‡]

多賀 祥平[†]
Shohei TAGA[†]
二瓶 泰雄[‡]
Yasuo NIHEI[‡]

松澤 智史[†]
Tomofumi MATSUZAWA[†]

東京理科大学[†] 創域情報学部[‡] 創域理工学部

[†]Faculty of Information Science and Technology/[‡]Faculty of Science and Technology, Tokyo University of Science

Abstract Since datasets for training dedicated models for such tasks are limited, utilization of general-purpose visual foundation models (VFMs) is beneficial. In this paper, we found that a newer VFM is not necessarily better: the previous-generation DINOv2 with LoRA outperformed the newer alternative in our comparative study.

1. はじめに

地震や津波等の自然災害は建物に甚大な被害をもたらすため、災害対応では発災後 24~48 時間以内の現地被害調査が求められる [1]。人手による調査には多大な負担が伴うため、画像に基づく自動被害分類が注目されている。しかし、従来の深層学習ベースの手法は大量のラベル付きデータを要する一方、災害ドメインの公開データセット [2, 3] で 1 タスクが供給する学習用に使える画像は数千~数万枚に留まる。

その制約を緩和する手段として、大規模データで事前学習された視覚基盤モデル (VFM) の利用が有望であるが、DINOv2 [4] やその後継の DINOv3 [5] 等の複数の選択肢があり、どのモデルが災害画像の分類タスクに適するかは自明でない。また、数億以上にも及ぶパラメータ全てを小規模データで Fine-tuning (Full FT) すると過学習のリスクがある。その対策として、重み更新を低ランク部分空間に制約する LoRA [6] と呼ばれる学習手法が知られているが、災害画像への体系的な適用は未検討である。筆者らの先行研究 [7, 8] も単一データセットでの検証に限られ、その結果が他のデータセットでも成立するかは未確認である。

そこで本稿では、どの基盤モデルを選び、どのように適応させるべきかに焦点を当て、4 つの災害画像データセットで系統的に検証する。データセット間で共通する知見が得られれば、少ないラベルと計算資源で分類器を迅速に構築でき、新しい VFM を採用する際の判断基準にも資する。

2. 関連研究

災害画像分類では、構造物の被害写真を集めた PHI-Net [2] や、SNS 投稿の災害画像から成る MEDIC [3] 等の公開データセットが整備され、これらを利用した GlimmerNet [9] 等の分類手法も報告されている。ただし、既報の分類手法はいずれも CNN を使い、その全パラメータを更新して学習する。

一方、VFM に関しては、1.42 億枚の画像 (LVD-142M) で自己教師あり学習された Vision Transformer (ViT) [10] として DINOv2 [4] が提案されている。さらに、後継の DINOv3 [5] では事前学習データが約 16.9 億枚 (LVD-1689M) へ拡大されている。

こうした大規模な事前学習済みモデルを、少数のパラメー

タで下流タスクに適応させる手法として LoRA [6] が提案されている。LoRA は、凍結した重み行列 $\mathbf{W}_0$ による変換に低ランク行列の積 $\Delta\mathbf{W} = (\alpha/r)\mathbf{BA}$ を加算し、行列 $\mathbf{A}$ と $\mathbf{B}$ のみを学習する。ランク r は両行列の共有次元であり、適応の自由度の上限を定める。これを VFM に適用する例はリモートセンシング分野で報告されている [11] が、地上撮影の災害画像への適用は筆者らによるものに限られる [7, 8]。

3. 手法

限られた災害画像でも過学習を抑えて基盤モデルを適応させ、かつ基盤モデル間・適応方法間の比較を公平に行うため、VFM を凍結したまま LoRA [6] アダプタとデータセットごとの分類ヘッドのみを学習する図 1 の構成を、全データセットに共通して採用する。

VFM には 304.4M パラメータの DINOv2 ViT-L/14 [4] を、比較対象として 303.1M パラメータの DINOv3 ViT-L/16 [5] を用いる。LoRA の低ランク補正は、入力特徴を Query・Key・Value (QKV) に変換する各線形層に導入する。スケール係数は $\alpha=r$ 、dropout は 0.1、入力解像度は能登地震と PHI-Net で 518×518 、AIDERv2 と MEDIC で 224×224 とする。ランクは PHI-Net と MEDIC では $r=8$ 、能登地震と AIDERv2 では $r=16$ とする。なお、DINOv2 と DINOv3 の比較では、条件を揃えるため全データセットで $r=16$ に固定する。例えば DINOv2 に $r=8$ を適用した場合、学習パラメータは 790,532 個と全体の 0.26% に留まる。また、AIDERv2 では予備実験でスクラッチ学習より高精度であったため、PHI-Net で学習したモデルからの転移学習を行う。最大エポック数と早期終了はデータセット別に設定する。最適化には AdamW を使い、混合精度で学習する。学習率と重み減衰は LoRA 学習で 3×10^{-5} と 10^{-4} 、Full FT で 1×10^{-5} と 10^{-3} とする。実験結果は原則、4 シードの乱




図 1 実験構成の全体像。

表 1 データセット横断比較 (Acc: Accuracy, W-F1: Weighted F1-score). 先行報告値は各原著の手法の値 (実験条件が異なる論文間比較; 指標は PHI-Net が Acc, 他は W-F1).

データセット	ドメイン	Acc (%)	W-F1 (%)	先行報告値
能登地震	地上写真	71.88±3.65	71.52±2.90	—
PHI-Net [2]	地上写真	79.87±0.83	80.06±0.82	74.50 (ResNet-50)
AIDERv2 [13, 9]	航空写真	99.53±0.06	99.53±0.06	96.60 (GlimmerNet)
MEDIC [3]	SNS 画像	81.98±0.19	83.86±0.14	80.40 (EffNet-B1)



図 2 能登地震テスト画像における予測の比較例. 緑は正解, 赤は誤答を示す.

数による平均 ± 標準偏差で報告し, 能登地震の DINOv2/v3 比較と表 2 のランク比較は 6 シードを用いる.

4. 実験と評価

4.1 データセットと評価指標

撮影条件やデータ規模の影響を考慮し, 次の 4 つのデータセットで評価する. 能登地震: 筆者らが構築した, 能登半島地震 (2024 年) の被災家屋画像を被害の種類と程度で 6 クラスに分けたデータセット [12] (計 1,040 枚, 80/20 固定分割で学習 832 枚・評価 208 枚), **PHI-Net Task 7** [2]: 地上写真による構造物被害分類 4 クラス (学習 4,138 枚), **AIDERv2** [13]: 航空写真による被害分類 4 カテゴリ (学習 13,399 枚), **MEDIC** [3]: SNS 画像による災害分類 3 クラス (学習 49,353 枚). 全データセットで Accuracy および重み付き F1 スコアを報告する.

4.2 各データセットにおける分類性能

表 1 に示すように, LoRA を適用した DINOv2 は 3 つの公開ベンチマーク全てで各原著の報告値を上回った. この結果は, データセットごとに専用モデルを設計せずとも, 凍結した基盤モデルと少数の追加パラメータの学習で, 条件の異なるデータセットに広く対応できることを示す.

4.3 データ規模に依存する DINOv2 と DINOv3 の性能差

最も小規模な能登地震 (学習 832 枚) では, DINOv3 の精度は $65.06 \pm 2.76\%$ であり, DINOv2 の $70.59 \pm 3.72\%$ を 5.53 ポイント下回った (6 シード全てで DINOv2 が優位, Wilcoxon $p=0.031$). この差は中規模の PHI-Net (4,138 枚) では 0.25 ポイントに縮小し, 規模が最大の MEDIC (49,353 枚) では実質的に消失した. パッチサイズの増大 (14→16, 空間トークン 1,369→1,024 個) も要因の一つとなり得るが, 解像度の違いとも交絡するため切り分けは今後の課題である. 図 2 に示すように, DINOv3 には津波被害を地震被害と混同する例や, 軽微な被害を見落とす例が見られた.

4.4 LoRA の暗黙的正則化効果

ランクの影響が最も明瞭に現れた PHI-Net での比較を表 2 に示す. 全パラメータを学習する Full FT の精度は 76.20% に留まり, 0.26% のみを学習する LoRA $r=8$ は 79.82% と 3.62 ポイント上回った. $r=8$ と $r=16$ の比較でも 6 シード全てで $r=8$ が優位であった (Wilcoxon

表 2 PHI-Net Task 7 における LoRA ランクと Full FT の比較. 割合は学習パラメータ数の全体比.

手法	r	学習パラメータ数	割合 (%)	Acc (%)
Full FT	—	304,371,716	100	76.20±1.22
LoRA	4	397,316	0.13	78.65±1.23
LoRA	8	790,532	0.26	79.82±0.90
LoRA	16	1,576,964	0.52	78.51±0.61

$p=0.031$). これは低ランク制約が正則化として機能することを支持する. なお他の 3 つのデータセットではランク間差が標準偏差内または 1 ポイント未満であった. 能登地震では分散が大きく, AIDERv2 と MEDIC では精度が飽和しているためであり, ランクの影響は中規模の PHI-Net で最も明瞭に現れた.

5. 考察

DINOv3 が小規模データセットで劣る要因としては, 事前学習データセットの分布適合性が考えられる. DINOv2 の事前学習データ LVD-142M は, 建造物や街路の画像を含むデータセットを基準に類似画像を検索して構築されており [4], 災害建物画像との分布類似性が高い. 一方, DINOv3 の LVD-1689M は Web 画像が中心で, 建物損傷写真の割合は相対的に小さい [5]. 分布距離が大きい DINOv3 では, 低ランクの更新だけでは適応しきれなかった可能性がある.

また, $r=8$ を頂点とするランク特性 (表 2) は, 学習に必要な自由度 (内在次元) が小さいほど汎化しやすいという報告 [14] と整合するが, 過剰なランク削減はかえって精度を下げ得ると解釈できる.

6. まとめ

本稿では, DINOv2 と DINOv3 を LoRA で 4 種の災害画像データセットに適応させて比較した. 最新の DINOv3 は予想に反して小規模データで DINOv2 に 5.53 ポイント劣り, この劣位は規模が最大の MEDIC ではじめて解消した. 一方, LoRA を適用した DINOv2 は全パラメータの 1% 未満の学習で 3 つの公開ベンチマークの報告値をすべて上回った.

【参考文献】

- [1] R. Gupta, et al.: "Creating xBD: A Dataset for Assessing Building Damage from Satellite Imagery", Proc. CVPR Workshops (June 2019)
- [2] Y. Gao, et al.: "PEER Hub ImageNet: A Large-Scale Multiattribute Benchmark Data Set of Structural Images", J. Struct. Eng., 146, 10 (Oct. 2020)
- [3] F. Alam, et al.: "MEDIC: A Multi-Task Learning Dataset for Disaster Image Classification", Neural Comput. Appl., 35, pp.2609-2632 (Jan. 2023)
- [4] M. Oquab, et al.: "DINOv2: Learning Robust Visual Features without Supervision", Trans. Mach. Learn. Res. (Jan. 2024)
- [5] O. Siméoni, et al.: "DINOv3", arXiv:2508.10104 (Aug. 2025)
- [6] E. J. Hu, et al.: "LoRA: Low-Rank Adaptation of Large Language Models", Proc. ICLR (Apr. 2022)
- [7] 山田 他: "ファインチューニング手法に基づく被災建物画像の多クラス損傷度分類の精度改善", 第 24 回情報科学技術フォーラム (FIT 2025), I-029, pp.339-340 (Sept. 2025)
- [8] 山田 他: "被災建物画像の多クラス損傷度分類におけるマルチタスク学習の有効性", 2026 年電子情報通信学会総大会, D12-80 (Mar. 2026)
- [9] D. Nedeljković: "GlimmerNet", arXiv:2512.07391 (Dec. 2025)
- [10] A. Dosovitskiy, et al.: "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", Proc. ICLR (May 2021)
- [11] S. Khanna, et al.: "ExPLoRA: Parameter-Efficient Extended Pre-Training to Adapt Vision Transformers under Domain Shifts", Proc. ICML (July 2025)
- [12] 鈴木 他: "被災家屋画像から被害度や種類を分類するシステムの構築", ソフトウェア・シンポジウム論文集, pp.39-45 (June 2025)
- [13] D. Shianios, et al.: "DiRecNetV2: A Transformer-Enhanced Network for Aerial Disaster Recognition", SN Comput. Sci., 5 (Aug. 2024)
- [14] A. Aghajanyan, et al.: "Intrinsic Dimensionality Explains the Effectiveness of Language Model Fine-Tuning", Proc. ACL-IJCNLP (Aug. 2021)