

視覚基盤モデルを利用した被災建物画像の自動被害分類

視覚基盤モデルによる小・中規模被災建物画像データセットの分類性能の比較

Comparison of Classification Performance Using Visual Foundation Models for Small- and Medium-Scale Datasets of Disaster-Damaged Buildings

山田 悠人[†] 鈴木 海友[†] 松田 一朗[†] 多賀 祥平[†] 松澤 智史[†] 柏田 仁[‡] 二瓶 泰雄[‡] 東京理科大学[†]創域情報学部/[‡]創域理工学部

小規模学習データ 832枚ではDINOv3 よりも一世代前のDINOv2が5.53ポイント上回った。

1 研究背景

用途は被災後の被害分析

- 災害画像は集まらない。
公開データセットでも1タスク数千～数万枚、
自作の能登地震は**832枚**
- 3億パラメータを全部更新すると**過学習する**



先行研究

既報はいずれもCNNの全パラメータ更新
衛星画像が中心で、地上の災害写真での研究は進められていない

問い：データ量が少ない被災建物画像で、
どの基盤モデルを選び、
どのように学習させるべきか

2 データセット

写真1枚を、そのデータセットのクラス1つに分ける
条件の違う4つで同じ結論になるかを見る



3 実験設定

構成は共通。動かす軸は2つ

被災家屋の写真 1枚

基盤モデル（約3億）は凍結
DINOv2 ViT-L/14 / DINOv3 ViT-L/16

各アテンション層に LoRA を挿入
学習するのは 0.26 % だけ

分類ヘッド（学習）
データセットごとに切り替える


6クラスのどれか

動かす軸① モデルの世代 DINOv2 / DINOv3


動かす軸② 学習量 全パラメータ更新 / LoRA $r=4, 8, 16$

答1 最新モデルが常に精度が高いとは限らない

① 学習 832枚 では、一世代前の DINOv2 が上



② 枚数が増えるほど、世代の差は消える



差の内訳（正解率 %, $r=16$ に固定）

データ	枚数	DINOv2	DINOv3	差
能登地震	832	70.59±3.72	65.06±2.76	+5.53
PHI-Net	4,138	78.31±0.59	78.06±1.39	+0.25
AIDERv2	13,399	99.24±0.13	99.38±0.17	-0.14
MEDIC	49,353	80.51±0.56	80.70±0.40	-0.19

差は DINOv2 - DINOv3
能登地震のみ6回すべてで DINOv2 が上 ($p=0.031$)
他の3つは標準偏差の範囲内

差の中身：DINOv3 は何を間違えたか

正解：津波(大)


正解：津波(小)



能登地震の評価画像。赤が誤答。誤りの傾向や頻度ではなく例示。

→ 誤りは隣接するクラスが中心。大きくは外していない。

答2 全パラメータ更新より LoRA の方が優位



→ 3.04億パラメータ全て更新するより

LoRAで0.26%だけ動かすほうが3.62ポイント高い。

LoRAが正則化として働いた可能性がある

補足 公開3データセットで既存の報告値（CNN系手法）を上回る

凍結したDINOv2+LoRAという構成を、撮影条件の違う3つの公開データセットに適用

PHI-Net 地上写真・正解率
74.50 ResNet-50 → **79.87** **+5.37**

AIDERv2 航空写真・重み付きF1
96.60 GlimmerNet → **99.53** **+2.93**

MEDIC SNS画像・重み付きF1
80.40 EffNet-B1 → **83.86** **+3.46**

→ 撮影条件の違う3つで、各原著のCNN系手法の報告値を上回った。

CNN系で全パラメータ更新よりDINOv2+LoRAの方が精度が高いことがわかった

結論


① 最新モデルだから精度が高いとは言い切れない

832枚では一世代前の DINOv2 が5.53ポイント上で、枚数が増えると差は消えた

② 全パラメータ更新より LoRA のほうが精度が高い

PHI-Netでは0.26 %だけ動かす LoRA が3.62ポイント上回った。

考察：なぜDINOv2が上回ったのか



- DINOv3はDINOv2 の画像をすべて含むが、**建物・街路の画像は増えていない**。
- 建物・街路以外の画像の種類が大幅に増えた分、全体に占める割合は下がった。
- 事前学習データの傾向が災害建物写真から遠く、LoRA だけでは適応しきれなかったと考えられる。