

# 視覚基盤モデルによる小・中規模被災建物画像 データセットの分類性能の比較

山田 悠人

東京理科大学 創域情報学部

映像情報メディア学会2026年年次大会 2026年8月28日

# 研究背景

- 地震や津波により，広範囲で建物被害が発生
- 被災画像から建物の被害状況を自動で分析したい
  - 人手による調査には専門知識が必要
  - 災害時に対応できる専門家の数には限りがある
- 被災画像の学習データを十分に集めることが難しい
  - 災害発生直後は被災画像を十分に集めにくい
  - 特にラベル付き画像の収集にはコストがかかる



能登半島地震の被害調査より


➡ 少量の被災画像でも高精度に分類できる手法が必要

# 視覚基盤モデル（Vision Foundation Models）について

## ➤ 膨大な画像データから学習し、さまざまな視覚タスクを幅広くこなせる汎用的なモデル

- 画像から特徴を抽出できる
- 学習済みの特徴を少量データの分類タスクに活用

### 本研究で比べる2つの VFM



## DINOv2/v3を使う理由

- DINOは自己教師あり学習による代表的なVFM
- ラベルなしの大規模画像から汎用的な視覚特徴を獲得

➡事前学習で獲得した特徴を活用することで、少量データのタスクにも適用可能

# 本研究が扱うタスク：被害画像分類

入力



分類器

出力

被害状況を表す  
クラスを1つ予測

被災した家屋を撮った地上写真1枚

(例：能登半島地震データセット)

例：能登半島地震では6クラス

地震・大破

地震・中破

地震・小破

津波・大破

津波・小破

被害なし


# 関連研究

## 災害画像の分類

- 災害画像の公開データセットが複数あり，それらを用いた分類手法が報告
- モデル全体を更新する手法が中心

## VFM+LoRAの関連研究

- 衛星画像へのVFM+LoRA適用例が報告
- 地上災害写真への適用例は限られる
- 複数データセットでのDINOv2/3比較は未検証




既存研究：衛星画像

➡ 災害画像では「どのVFM」を「どう適用」させるべきかが未解明

# 課題1：VFMの選択

DINOv2 (1.42億枚)

DINOv3 (約16.9億枚)



異なるタスクでDINOv3が一貫して上回る

■ DINOv2 ■ DINOv3

一般タスクで高性能なDINOv3は，少量の災害画像分類でも優れるか？

[4] Oquab+ 2024 (DINOv2) / [5] Siméoni+ 2025 (DINOv3) Table 14 の ViT-L の値 (DINOv2 側も同論文による同一条件での再評価値)

## 課題2：少量データでは，VFMをどう適用させるべきか

### Full FT

全パラメータを更新  
更新パラメータ：約3億


### LoRA

一部のパラメータのみ更新  
更新パラメータ：約79万 ( $r=8$ )

### ランク $r$

$r$ が小さい → 更新パラメータ数が少ない  
 $r$ が大きい → 更新パラメータ数が多い

### LoRAの構成



$$\Delta W = BA \quad r = \text{低ランク行列の中間次元 (ランク)}$$

### 少量の災害画像では？

- ① Full FT vs LoRA
- ② ランク  $r$  と精度の関係

# 本研究の目的

## 問い1 | どのVFMか

DINOv2 vs DINOv3

## 問い2 | 適用方法

全パラメータ更新 vs LoRA

LoRAのランク  $r$

- 4つの災害画像データセットを用いて，VFMと学習方法による性能差を明らかにする
- 4つのデータセットを用いる理由
  - 撮影条件・データ規模によって，モデル・学習方法の優劣がどう変化するかを検証
  - 地上写真・航空写真・SNS画像
  - 学習データ数：832枚～49,353枚
- 想定場面：被災直後の限られた災害画像を用いた画像分類

# 災害画像データセット①：能登地震（筆者ら構築）



地震・大



地震・中



地震・小



津波・大



津波・小



被害なし


| 種類 \ 被害度 | 大       | 中       | 小       |
|----------|---------|---------|---------|
| 地震       | E1 313枚 | E2 112枚 | E3 98枚  |
| 津波       | T1 88枚  | —       | T3 126枚 |
| 被害なし     | 303枚    |         |         |

計1,040枚の能登半島地震データセット

# 災害画像データセット②～④：公開データセット

## PHI-Net Task 7 (学習4,138枚)

- 建物拡大写真 | 4クラス
- 目的：構造物の損傷度評価



無被害 919枚



軽微 869枚



中程度 799枚



重度 1,551枚

## AIDERv2 (学習13,399枚)


- 航空・ドローン写真 | 4クラス
- 目的：災害種別の認識



地震 1,927枚



火災 3,509枚



洪水 4,063枚



通常 3,900枚

## MEDIC (学習49,353枚)

- SNS投稿画像 | 3クラス
- 目的：SNS画像から災害対応情報を抽出



軽微～被害なし  
28,314枚




中程度  
3,904枚



重大  
17,135枚

[1] Gao+ 2020 (PHI-Net) / [9] Shianios+ 2024 (AIDERv2) / [2] Alam+ 2023 (MEDIC) / 見本は各データセットの実データより

# 実験構成



データセットごとに  
分類ヘッドを学習


➡ 各条件で4データセットを個別の学習・評価

# 実験結果1：先行研究との比較

| データセット（撮影）  | 指標     | 先行研究 → 本手法                                 |
|-------------|--------|--------------------------------------------|
| 能登地震（地上）    | 正解率    | 先行研究なし 71.88±3.65                          |
| PHI-Net（地上） | 正解率    | 74.50 ResNet-50 → <b>79.87±0.83 +5.37</b>  |
| AIDERv2（航空） | 重み付きF1 | 96.60 GlimmerNet → <b>99.53±0.06 +2.93</b> |
| MEDIC（SNS）  | 重み付きF1 | 80.40 EffNet-B1 → <b>83.86±0.14 +3.46</b>  |

先行研究のスコア：[1] Gao+ 2020／[3] Nedeljković 2025／[2] Alam+ 2023.


## 実験結果2：DINOv2とDINOv3の比較



➡ 最小規模の能登地震ではDINOv2が優位，他の3つのデータセットでは差は小さい

# 考察：事前学習画像との類似性が影響した可能性

能登地震のみDINOv2が大きく上回り，他3データセットではほぼ同等



[5] Siméoni+ 2025 (DINOv3) Sec.3.1：Instagram公開投稿由来のWeb画像プールから構築

## 実験結果2：DINOv3の誤分類例

正解ラベル：津波 | 大破



DINOv2：津波 | 大破 ✓

DINOv3：地震 | 大破 ✕

正解ラベル：被害なし



DINOv2：被害なし ✓

DINOv3：地震 | 小破 ✕

正解ラベル：津波 | 小破




DINOv2：津波 | 小破 ✓

DINOv3：被害なし ✕

➡ DINOv3の誤りは，災害種別や隣接する被害度の取り違えを確認

# 実験結果3：LoRAのランクによる精度変化（PHI-Net）



※他データセットでもランクによる傾向は異なり、共通の最適値は確認されなかった

LoRAは多くのランクでFull FTを上回り、ランク選択で精度が変化

# まとめ

① 基盤モデル      能登地震ではDINOv2がDINOv3より**+5.53pt**  
→ **事前学習画像との類似性が影響した可能性**

② 適応方法      LoRAが全パラメータ更新を上回った  
→ **PHI-Netでは最大+3.62pt**

③ LoRAランク      最適なランクはデータセットで異なる  
→ **共通するランクは確認できず**

**3つの公開データセットすべてで先行研究の報告値を上回った**

# 謝辞

本研究は、東京理科大学マルチハザード都市防災研究拠点の  
ご支援を受けて行われました。  
ご協力いただいた関係機関の皆様に深く感謝いたします。

ご清聴ありがとうございました

# Appendix

質疑応答用の補足資料

# 参考文献

- [1] R. Gupta, et al.: “Creating xBD: A Dataset for Assessing Building Damage from Satellite Imagery”, Proc. CVPR Workshops (2019)
- [2] Y. Gao, et al.: “PEER Hub ImageNet: A Large-Scale Multiattribute Benchmark Data Set of Structural Images”, J. Struct. Eng., 146, 10 (2020)
- [3] F. Alam, et al.: “MEDIC: A Multi-Task Learning Dataset for Disaster Image Classification”, Neural Comput. Appl., 35, pp.2609-2632 (2023)
- [4] M. Oquab, et al.: “DINOv2: Learning Robust Visual Features without Supervision”, Trans. Mach. Learn. Res. (2024)
- [5] O. Siméoni, et al.: “DINOv3”, arXiv:2508.10104 (2025)
- [6] E. J. Hu, et al.: “LoRA: Low-Rank Adaptation of Large Language Models”, Proc. ICLR (2022)
- [7] 山田 他: “ファインチューニング手法に基づく被災建物画像の多クラス損傷度分類の精度改善”, FIT2025, I-029, pp.339-340 (2025)
- [8] 山田 他: “被災建物画像の多クラス損傷度分類におけるマルチタスク学習の有効性”, 2026年電子情報通信学会総合大会, D12-80 (2026)
- [9] D. Nedeljković: “GlimmerNet”, arXiv:2512.07391 (2025)
- [10] A. Dosovitskiy, et al.: “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”, Proc. ICLR (2021)
- [11] S. Khanna, et al.: “ExPLoRA: Parameter-Efficient Extended Pre-Training to Adapt Vision Transformers under Domain Shifts”, Proc. ICML (2025)
- [12] 鈴木 他: “被災家屋画像から被害度や種類を分類するシステムの構築”, ソフトウェア・シンポジウム論文集, pp.39-45 (2025)
- [13] D. Shianios, et al.: “DiRecNetV2: A Transformer-Enhanced Network for Aerial Disaster Recognition”, SN Comput. Sci., 5 (2024)
- [14] A. Aghajanyan, et al.: “Intrinsic Dimensionality Explains the Effectiveness of Language Model Fine-Tuning”, Proc. ACL-IJCNLP (2021)

# 付録A：ランクの選定理由

| データセット  | $r$ | その値にした理由                                                |
|---------|-----|---------------------------------------------------------|
| PHI-Net | 8   | ランクだけを変えた比較で最も高精度（6回の学習， $p = 0.031$ ）                  |
| MEDIC   | 8   | 事前のランク比較で $r = 8$ が $r = 16$ より高精度だったため                 |
| AIDERv2 | 16  | PHI-Netで学習した $r = 16$ の重みを使うので，行列の大きさを合わせた              |
| 能登地震    | 16  | DINOv2とDINOv3の比較の設定（ $r = 16$ ）に合わせた． $r = 8$ との差は誤差の範囲 |

- 4つとも最高値を選んだわけではない
  - ・ 比較実験の結果・転移学習の制約・比較条件の統一を使い分けた
- $r$  の値そのものは評価データの結果を見て決めた（上の表に3つすべてを載せている）
  - ・ 各学習の停止点は検証データで決めている（付録B）

| $r$ | LoRA ( $98,304 \times r$ ) | +ヘッド  | 計         |
|-----|----------------------------|-------|-----------|
| 4   | 393,216                    | 4,100 | 397,316   |
| 8   | 786,432                    | 4,100 | 790,532   |
| 16  | 1,572,864                  | 4,100 | 1,576,964 |

内訳：24層  $\times$  4,096  $\times r$  + 分類ヘッド

# 付録B：統計検定と学習設定

## ➤ 統計検定

- **Wilcoxon符号付き順位検定（両側）**．同じ乱数の種どうしを対にして比べた
- 能登地震DINOv2とv3：6回ともDINOv2が上， $p = 0.031$
- PHI-Net  $r = 8$ と  $r = 16$ ：6回とも  $r = 8$ が上， $p = 0.031$

6回の両側検定で  $p$  が取り得る最小値が0.03125である．学習を4回から6回に増やしたのは，結果を見る前に回数を決めてから実施した

## ➤ 実験1と実験3で値が少し違う理由

実験1のPHI-Net（79.87±0.83，4回）と実験3の  $r = 8$ （79.82±0.90，6回）は学習回数が違うだけで，設定は同一

| 項目       | LoRA                | Full FT            |
|----------|---------------------|--------------------|
| 学習率      | $3 \times 10^{-5}$  | $1 \times 10^{-5}$ |
| 重み減衰     | $10^{-4}$           | $10^{-3}$          |
| 学習パラメータ数 | 790,532 ( $r = 8$ ) | 304,371,716        |

## ➤ モデル選択に使ったデータ

- 学習4,138枚を **train 3,724 / val 414**に層化分割
- 停止と最良点は **valのmacro-F1**
- 報告は**評価データの正解率**．選ぶ側と報告側を分けている

## ➤ その他の設定

- AdamW・混合精度． $\alpha = r$ ，dropout 0.1

# 付録C：AIDERv2の転移学習と入力解像度

## ➤ AIDERv2 は LoRA だけでも精度が出る

- そこへ PHI-Net で学習した  $r=16$  の重みを初期値にするとさらに向上
- 予備実験で確認し、この設定を採用した
- 重みを引き継ぐため、AIDERv2 のランクも  $r=16$  に揃えた

実験1の AIDERv2 の行はこの転移学習の結果．一から学習した手法との比較ではない

## ➤ 入力解像度を使い分けた理由

- 能登地震・PHI-Net：518×518（枚数が少なく，細部まで見せたい）
- AIDERv2・MEDIC：224×224（枚数が多く，計算量を抑えたい）

DINOv2とDINOv3の比較では，2つのモデルで解像度を揃えた条件だけを使っている

### 能登地震データセットの補足

撮影の角度と距離はそろっていない．クラスごとの枚数にも偏りがある

地震 大313・中112・小98／津波 大88・小126／被害なし303（計1,040枚）

# 付録D：MEDICのデータ分割

- **MEDICは複数の分類課題を含むデータセット**
  - ・本研究が使ったのは被害度（3クラス）の課題だけ
- **学習枚数49,353枚はHugging Face配布版（QCRI/MEDIC）の分け方によるもの**
  - ・原論文Table 4の42,179枚とは**学習用と評価用の分け方が違う**
  - ・実験1で比較に用いた80.40（EffNet-B1）は，原論文が報告した値

➡ 実験1の3つはいずれも各論文の報告値との比較であると明示している

# 付録E：LoRAの計算順序について

## ▶ 数式上は $W = W_0 + \Delta W$ , $\Delta W = BA$

- つまり  $(W_0 + \Delta W)x$  と  $W_0x + \Delta Wx$  は数式としては同じ

## ▶ 実装では $W_0$ と $\Delta W$ を先に足さず， $W_0x$ と $\Delta Wx$ を別々に計算してから足す

- 図の「+」は，この2つの経路の出力を足す処理を表している

浮動小数点演算では計算順序によって丸め誤差の出方がわずかに変わりうるが，結果に実質的な影響はない

➡  $W_0$  を凍結したまま，追加経路の出力だけを足し合わせている