連絡先

yuto.yamada0101@gmail.com

www.linkedin.com/in/悠人-山田-156149304 (LinkedIn)

トップスキル

PyTorch

Machine Learning

MLOps

Certifications

Data Science Education Program Level 3 (Specialization)

CS50x: Introduction to Computer Science

日商簿記検定3級

山田 悠人

東京理科大学在学

広域東京エリア

職歴

株式会社松尾研究所 / Matsuo Institute

AIエンジニア

2026年2月 - Present (2ヶ月)

LegalOn Technologies

AIエンジニア

2026年2月 - Present (2ヶ月)

日本 東京都 渋谷区

株式会社ソリューション・アンド・テクノロジー

システムエンジニア

2023年7月 - Present (2年 9ヶ月)

日本 東京都

As an intern assigned to the DX Division at SOLTY, a company specializing in HR, accounting, and business systems, I have been responsible for developing internal AI solutions, automation tools, and efficiency improvements. My AI-related work includes building a resignation risk prediction model using in-house HR data, implementing document similarity logic via NLP, constructing a mail sentiment analysis and misdelivery detection system using Azure OpenAI, and developing an internal document search system with Retrieval-Augmented Generation (RAG) using Azure AI Search.

In addition, I have worked on automating the extraction of work attendance data through web scraping and improving OCR accuracy for receipt reading through image preprocessing and tuning. I also developed a company-specific to-do list application using Django and React, focusing on state management and UI/UX improvements. I have participated in AI prototyping by conducting business hearings and building proof-of-concept models.

Technologies used include Python, Java, SQL, Django, Next.js, React, Redux Toolkit, Tailwind CSS, Azure OpenAI, Azure AI Search, OCR, and web scraping.

人事・会計・業務管理領域に特化した業務システムを展開する企業にて、DX統括部にインターンとして所属し、主に社内向けのAIシステム開発・自動化支援・業務効率化を担当しています。AI関連では、社内の人材データを活用した退職リスク予測モデルの構築、自然言語処理による文書間類似度の判定、Azure OpenAIを用いたメール文面の感情分析・誤送信検出システム、そしてAzure AI Searchを活用したRetrieval-Augmented Generation（RAG）型の社内ドキュメント検索システムなどを開発しました。

また、Webスクレイピングによる勤怠データ自動取得や、レシートOCR精度向上のための画像前処理・パラメータチューニングなど、業務自動化や品質改善にも取り組んでいます。さらに、DjangoとReactによる社内To-Doアプリの開発・UI改善や、業務ヒアリングからのAIプロトタイピング（PoC設計・検証）など、幅広い領域で実装と検証を担当しています。

使用技術はPython、Java、SQL、Django、Next.js、React、Redux Toolkit、Tailwind CSS、Azure OpenAI、Azure AI Search、OCR、Webスクレイピングなどです。

Airion株式会社

AI開発事業部/AI Engineer（Machine Learning / Computer Vision / NLP）

2024年4月 - Present (2年)

東京都, 日本

I am an AI Engineer at Airion Inc., working in the AI Development Division. I have been involved in multiple AI projects, including speech synthesis, image processing, object detection, optimization, 3D data analysis, and document automation. My responsibilities include model design, implementation, data processing, evaluation, technical documentation, and comparative analysis.

In the GENIAC project, a national AI initiative led by METI and NEDO, I participated in the research and development of a large language model for automatic ladder logic generation. I was responsible for designing and implementing an automatic summary evaluation script using LLM-as-a-Judge.

In addition, I have worked on a variety of tasks including the development of a real-time TTS system using VITS2, architectural image correction algorithms, endoscopic image enhancement, 3D segmentation for industrial defect detection, document generation from structured text, and steel pipe counting model development and evaluation based on YOLOv8.

Technologies used include Python, PyTorch, YOLOv8, OpenCV, VITS2, OCR, CVAT, Roboflow, Pandas, NumPy, Matplotlib, ControlNet, LoRA, VAE, Optuna, and SMAC3.

株式会社AirionのAI開発事業部に所属し、音声合成、画像処理、物体検出、最適化、3Dデータ解析、文書処理などの複数のAI開発プロジェクトに従事しています。モデル設計、実装、データ処理、評価、報告資料の作成、比較検証などを担当しています。

経済産業省およびNEDOが推進する国家プロジェクト「GENIAC」においては、ラダープログラムの自動生成に関する大規模言語モデル（LLM）の研究開発に参加しました。このプロジェクトでは、生成結果の要約を自動的に評価するため、LLM-as-a-Judgeを活用したスクリプトの設計と実装を担当しました。

そのほか、VITS2を用いたリアルタイム音声合成モデルの開発、建築パース画像補正のアルゴリズム設計、内視鏡画像の画質最適化、3Dセグメンテーションを用いた工業部品の異常検出、文書構造解析に基づく仕様書自動生成、YOLOv8をベースとした鉄パイプ自動計数モデルの開発・検証など、幅広いテーマに取り組んでいます。

使用技術には、Python、PyTorch、YOLOv8、OpenCV、VITS2、OCR、CVAT、Roboflow、Pなどが含まれます。

株式会社MIXI
機械学習エンジニア
2025年10月 - 2025年11月 (2ヶ月)
東京都

家族アルバム共有サービス「みてね」のMLグループにて、機械学習パイプラインの最適化とAWSインフラ効率化に従事。Vision-Language Modelによる画像処理システムの高速化とコスト削減を実現。
主な成果:
・ Image Captioning高速化: Vision Encoder出力のベクトル再利用により、Qwen3-VL 2Bモデルの推論速度を42.8%向上（0.47秒→0.27秒）
・ SQS Visibility Timeout最適化: 統計分析によりタイムアウト設定を900秒から65秒へ92.8%短縮。エラー復旧時間を15分から1分強へ削減
・ S3アップロード並列化: ThreadPoolExecutorによる並列化で高解像度画像の処理を30.7%高速化、スループット4倍向上、1回の実行あたり約1万円のコスト削減を達成

使用技術: Python, PyTorch, Transformers, AWS (SQS, S3, EC2), Kubernetes, Docker, New Relic, Grafana

---

ML Group Intern at "mitene" (family photo sharing service). Optimized machine learning pipelines and AWS infrastructure for image processing systems using Vision-Language Models. Achieved performance gains and cost reductions through data-driven approach with New Relic and Grafana analysis.
Key Achievements:
・ Image Captioning Acceleration: Achieved 42.8% speedup (0.47s→0.27s) in Qwen3-VL 2B model inference by implementing vision encoder output vector reuse strategy. Designed vector caching mechanism for improved processing efficiency.
・ ML Pipeline Architecture Enhancement: Refactored to Pydantic-based declarative validation architecture. Reduced 130 lines of code while implementing Single Responsibility and DRY principles for maintainable design.
・ SQS Visibility Timeout Optimization: Reduced timeout settings from 900s to 65s (92.8% reduction) through statistical analysis. Reduced error recovery time from 15 minutes to just over 1 minute.
・ S3 Upload Parallelization: Built parallel upload infrastructure using ThreadPoolExecutor. Parallelized 4 files achieving 30.7% speedup for high-resolution images, 4x throughput improvement (1-2 to 6-8 req/min), and ¥10,000 cost reduction per batch run.
Technologies: Python, PyTorch, Transformers, AWS (SQS, S3, EC2), Kubernetes, Docker, New Relic, Grafana

エン・ジャパン(株)
フルスタックエンジニア
2025年9月 - 2025年9月 (1ヶ月)

I participated in en-japan’s engineering internship program, where I developed a mini job-site web application using a modern architecture with separated frontend and backend.
The backend was implemented in Python following the MVC+S+R architecture, while the frontend used Next.js/React as a Single Page Application (SPA). I set up the environment using Docker/devcontainer, implemented API-compliant features, and worked through GitHub Flow by creating feature branches, submitting pull requests, and addressing code reviews.
Through this internship, I gained practical experience in responsibility separation, reproducible development, error handling, and collaborative workflows with code reviews. This experience strengthened my ability to

design and deliver robust web applications, which I aim to apply to future AI/ML system development as well.

エン・ジャパンのエンジニアリンググループにて、求人サイトを題材としたモダンWebアプリケーション開発に取り組みました。
バックエンドはPythonを用いたMVC+S+Rアーキテクチャ、フロントエンドはNext.js/ReactによるSPA構成で開発を行いました。Docker/devcontainerで環境構築を行い、API仕様に準拠した機能実装やテストを経験しました。また、GitHub Flowに基づいてfeatureブランチ作成、Pull Request提出、コードレビュー対応を繰り返すことで、実務に近い開発プロセスを体験しました。
この経験を通じて、責務分離や例外処理、再現性を意識した開発、レビューを通じたチームコラボレーションの重要性を学びました。今後はAI/MLシステムの設計・開発にも活かしていきたいと考えています。

Technologies / 使用技術:
Python, Next.js, React, Docker, devcontainer, GitHub Flow, API design

株式会社エクサウィザーズ
機械学習エンジニア
2025年8月 - 2025年9月 (2ヶ月)

Machine Learning Engineer Intern — ExaWizards Inc.
Sep 2025 (1 month) | Tokyo, Japan
• Contributed to the development of AI agents and machine learning solutions addressing real-world challenges in AI and data-driven services.
• Engaged in prototyping, evaluation, and improvement of models with a focus on practical implementation.
• Collaborated with team members in an agile environment, balancing research and engineering practices.

Key Achievements:
• Delivered a functional prototype aligned with business and research needs.
• Strengthened practical skills in AI agent design, machine learning model development, and explainability.

Skills & Keywords:
AI Agent, Machine Learning, Computer Vision, AI Prototyping, Agile Development, Model Evaluation, Explainable AI

#

機械学習エンジニア インターン — 株式会社エクサウィザーズ
2025年9月（1ヶ月）| 東京
• AIエージェント や機械学習を活用した実課題の解決に取り組み、データドリブンサービスの開発を担当。
• 実装を重視したプロトタイピング・評価・改善を実施。
• チームメンバーとアジャイル環境で協働し、研究とエンジニアリングを両立。

成果:
• 事業・研究双方のニーズに沿ったプロトタイプを完成。
• AIエージェント設計、機械学習モデル開発、説明可能性に関する実践的スキルを強化。

スキル・キーワード:
AIエージェント、機械学習、コンピュータビジョン、AIプロトタイピング、アジャイル開発、モデル評価、説明可能AI

Goldman Sachs
エンジニアリング部門
2025年8月 - 2025年8月 (1ヶ月)

Goldman Sachs | Engineering Division Workshop (2025)
1-day intensive workshop on Finance × Technology
•Experienced the forefront of financial engineering and trading systems.
•Designed, implemented, and presented a mock FX trading system, covering the full cycle from algorithm design to performance evaluation.
•Engaged with Goldman Sachs engineers to explore global-scale development environments, career paths, and collaborative culture.
•Gained insights into agile decision-making, logical problem-solving, and the fusion of technical and business perspectives required in global financial technology.

ゴールドマン・サックス | エンジニアリング部門 ワークショップ（2025）
•金融×テクノロジーの最前線におけるエンジニアの役割を体感。
•模擬FXトレードシステムの設計・実装・発表を通じて、アルゴリズム構築から成果検証までを実践。
•現役エンジニア社員との交流を通じて、グローバルな開発環境・キャリアパス・働き方を理解。
•技術力に加え、即応性・論理的思考・ビジネス視点の重要性を学ぶ。

株式会社ログラス
エンジニア職
2025年8月 - 2025年8月 (1ヶ月)

Software Engineer Intern — Loglass, Inc.
Aug 2025 (5 days) | Tokyo, Japan
•Developed a financial reporting system (Profit & Loss Statement / Balance Sheet) using Domain-Driven Design (DDD) and Scrum methodology.
•Designed and implemented System Context, Use Case, Object, and Domain Model diagrams to align business requirements with software architecture.
•Built backend with Spring Boot (Kotlin), MySQL, and Docker, applying Layered Architecture and Dependency Inversion Principle (DIP) to ensure maintainability and scalability.
•Participated in two Scrum sprints (2.5 days each) covering Sprint Planning, Daily Stand-ups, Sprint Reviews, and Retrospectives (KPT).
•Improved development efficiency through Pair Programming, Mob Programming, and AI-assisted debugging.

Key Achievements:
•Delivered a functional PL/BS generation prototype within 5 days.
•Enhanced code maintainability by applying DDD patterns and clean architecture principles.

Skills & Keywords:
Domain-Driven Design (DDD), Scrum, Agile Development, Spring Boot, Kotlin, MySQL, Docker, Layered Architecture, Dependency Inversion Principle (DIP), System Modeling, UML, Pair Programming, Mob Programming, AI-assisted Development, Financial Systems Development

ソフトウェアエンジニア インターン — 株式会社ログラス
2025年8月（5日間）| 東京
•ドメイン駆動設計（DDD）とスクラム開発を活用し、損益計算書（PL）・貸借対照表（BS）作成システムを開発。
•システム関連図・ユースケース図・オブジェクト図・ドメインモデル図を作成し、業務要件とソフトウェア設計を統合。
•Spring Boot（Kotlin）・MySQL・Dockerによるバックエンド構築、レイヤードアーキテクチャと依存性逆転の原則（DIP）を適用し、保守性と拡張性を確保。

•2.5日×2スプリントのスクラムを実施（プランニング、デイリースクラム、レビュー、KPT振り返り）。
•ペアプロ・モブプロとAI支援開発により、開発効率を向上。

成果:
•5日間でPL/BS生成プロトタイプを完成。
•DDDパターン適用により、コードの保守性・拡張性を強化。

スキル・キーワード:
ドメイン駆動設計（DDD）、スクラム、アジャイル開発、Spring Boot、Kotlin、MySQL、Docker、レイヤードアーキテクチャ、依存性逆転の原則（DIP）、システムモデリング、UML、ペアプログラミング、モブプログラミング、AI支援開発、会計システム開発

GMO Media, Inc.
GMOインターネットグループ（GMOメディア株式会社）｜機械学習エンジニア インターン
2025年7月 - 2025年8月 (2ヶ月)
東京都渋谷区桜丘町26-1 セルリアンタワー

Worked in the AI Data Promotion Team on predictive modeling for affiliate marketing, focusing on approval revenue prediction and approval month prediction.

Key Contributions & Achievements:
•Developed approval/rejection prediction model (Accuracy: 96.1%, AUC: 0.965, F1-score: 0.978)
•Built approval timing prediction model (MAE: 1.3 days; Over 99% month prediction accuracy for high-confidence cases)
•Designed and implemented extensive feature engineering (temporal, monetary, categorical, text-based, and interaction features)
•Introduced a confidence score framework to classify predictions into high/medium/low confidence, enabling model switching for improved accuracy
•Automated BigQuery-to-Google Sheets pipeline for weekly prediction updates accessible to business directors
•Reduced manual workload for approval date estimation and improved cash flow forecast accuracy

Tech Stack: Python, LightGBM, scikit-learn, pandas, numpy, BigQuery, Google Cloud Platform, matplotlib, seaborn

AIデータ推進チームにて、アフィリエイトマーケティングにおける承認売上予測と承認月予測をテーマに機械学習モデルを構築。

主な成果と貢献:
•承認/否認予測モデルの構築（精度: 96.1%、AUC: 0.965、F1スコア: 0.978）
•承認時期予測モデルの開発（MAE: 1.3日、高信頼度データでは月予測正解率99%以上）
•時間・金額・カテゴリ・テキスト・交互作用など多様な特徴量エンジニアリングを実装
•予測結果を高・中・低の信頼度スコアで分類し、モデル切替による精度改善を実現
•BigQueryからGoogleスプレッドシートへの自動反映パイプラインを構築し、週次で予測更新を共有
•承認日予測の工数削減とキャッシュフロー計画精度の向上に貢献

使用技術: Python、LightGBM、scikit-learn、pandas、numpy、BigQuery、Google Cloud Platform、matplotlib、seaborn

株式会社スタンバイ
MLエンジニア
2025年7月 - 2025年8月 (2ヶ月)

Machine Learning Engineer Intern (4 days) – Standby Inc.
Participated in a practical, on-site internship at Standby Inc. (a joint venture of LINE Yahoo and BizReach).
•Tackled real-world business challenges through factor analysis, solution design, and ML implementation.
•Delivered final results to the CTO, with opportunities for integration into actual products.
•Strengthened skills in data-driven problem solving and engineering-focused solution planning.

スタンバイ株式会社 | MLエンジニア インターン（4日間, 実務課題型）
LINEヤフー×ビズリーチの合弁企業で、オフライン形式の短期インターンに参加。
•実際の課題を題材に、要因分析・解決策立案・ML実装を実施
•CTOへの成果発表を行い、実プロダクトへの反映機会あり
•データドリブンな課題解決力とエンジニア視点での企画力を強化

Geniee International Pte.Ltd

1-Day Technical Internship

2025年7月 - 2025年7月 (1ヶ月)

Joined a 1-day technical internship focused on optimizing the performance of a Demand-Side Platform (DSP) for ad delivery. Implemented measures including mitigation of the N+1 query issue via batch DB access, response acceleration via TTL caching, dynamic threading based on feature data size, and true parallel processing with multiprocessing and prefork architecture. Used Prometheus and Grafana to monitor system metrics and visualize performance. Gained hands-on experience in full-cycle optimization—from system design to implementation and monitoring—under realistic traffic conditions.

Tech Stack:
Python 3.12 / MySQL / Prometheus / Grafana / Docker / Multithreading & Multiprocessing / Cache Design / Performance Visualization

広告配信処理のパフォーマンス最適化をテーマに、MySQLのN+1問題解消、TTLキャッシュによるレスポンス高速化、スレッド・プロセス並列処理の導入、Prometheus + Grafanaによる可視化・メトリクス分析を実施。GIL対策としてmultiprocessing + プリフォーク構成を採用し、実運用を想定した負荷条件下での高速化を実現。最適化設計・実装・パフォーマンス分析までを一貫して担当。

使用技術：
Python 3.12 / MySQL / Prometheus / Grafana / Docker / 並列処理（マルチスレッド・マルチプロセス）/ キャッシュ設計 / 性能可視化

(株)サイバーエージェント [CyberAgent]

Architecture Challenge

2025年6月 - 2025年6月 (1ヶ月)

Participated in a selective workshop focused on designing scalable architecture for a multi-tenant platform. Designed a microservices-based system using technologies such as ECS Fargate and API Gateway, while considering SRE, infrastructure, security, and cost optimization. Received detailed reviews from professional engineers at CyberAgent and learned best practices regarding tenant separation, shared architecture, and mitigation of the noisy neighbor problem.

Tech Stack:

AWS (ECS Fargate, API Gateway, CloudFront, ElastiCache, SQS, CloudWatch, X-Ray) / Microservices / Auto Scaling / WAF / JWT Authentication / RBAC / Observability

マルチテナンシーなプラットフォームにおけるアーキテクチャ設計をテーマに、ECS FargateやAPI Gatewayなどを活用したスケーラブルなマイクロサービス構成を設計。SRE・インフラ・セキュリティ・コスト最適化を総合的に考慮した設計を行い、社員エンジニアからのレビューを受けながら設計力を高めました。マルチテナント設計における分離と共通化のバランス、ノイジーネイバー問題への対処などの知見を得ました。

技術スタック：
AWS（ECS Fargate, API Gateway, CloudFront, ElastiCache, SQS, CloudWatch, X-Ray）/ マイクロサービス / オートスケーリング / WAF / JWT認証 / RBAC / 可観測性

Rakuten
アプリケーションエンジニア インターン（Application Engineer Intern – Prototype Development Track）
2023年8月 - 2023年8月 (1ヶ月)
日本 東京都

Participated in a prototype development internship at Rakuten Group, Inc., designing and implementing a cross-platform mobile app using Flutter and Dart. Focused on UI/UX design, state management, and modular architecture, and completed the entire cycle from requirement definition to final presentation within a week, gaining practical mobile development and teamwork experience.

新規プロトタイプ開発インターンに参加し、FlutterとDartを用いてクロスプラットフォームのモバイルアプリを設計・実装しました。UI/UX設計、状態管理、コンポーネント分割などに配慮し、要件定義からプロトタイプ構築、最終プレゼンテーションまでを短期間で完遂。実践的なアプリ開発経験とチーム開発スキルを習得しました。

使用技術｜Tech Stack
Flutter / Dart / Mobile App Development / UI Design / State Management / Team Collaboration

株式会社Shinonome
データサイエンティスト（Data Scientist）
2021年4月 - 2023年6月 (2年 3ヶ月)

日本 東京都

At Shinonome Inc., an AI solution company, I worked on real-world NLP and blockchain-related projects as a data scientist assistant. In the diary-generation AI project, I researched state-of-the-art paraphrasing methods and implemented them using Python-based NLP libraries. I also designed and optimized prompts to improve output diversity and naturalness for generative models.

In another project with SMTB, I contributed to a blockchain-based transaction system leveraging solar power generation data. My responsibilities included designing and executing unit and integration tests to ensure system reliability and uncover software issues. Additionally, I supported junior engineers through code reviews and continuously worked on improving code quality, bug fixing, and strengthening system security.

AI受託開発企業である株式会社Shinonomeにて、自然言語処理やブロックチェーン技術を活用した実践的なプロジェクトに従事しました。日記生成AIの開発では、Paraphrase（言い換え）技術の最新論文を調査し、Pythonによる自然言語処理モデルの実装やプロンプト設計に取り組みました。生成文の多様性と自然さの向上に寄与しました。

また、SMTBの太陽光発電プロジェクトでは、再生可能エネルギーとトークンエコノミーを組み合わせたブロックチェーン取引に関するテスト設計と品質検証を担当。単体テスト・統合テストを通じてシステムの信頼性向上に貢献しました。加えて、後輩エンジニアへのコードレビューや、バグ修正・セキュリティ強化といった品質改善の取り組みにも継続的に携わりました。

株式会社松尾研究所

AI技術開発・実用化支援 / 戦略コンサルティング（AI Engineer / Strategy Consulting）

2023年1月 - 2023年5月 (5ヶ月)

日本 東京都

At Matsuo Institute, I participated in a digital transformation (DX) project for one of Japan’s top food manufacturing companies. Although I joined from an AI engineering background, my role focused on supporting strategic consulting activities. I contributed to estimating market size and business impact using Fermi estimation techniques and conducted market and competitor research to support strategy development.

I was also responsible for preparing executive-facing presentation materials and participated in weekly management meetings involving top-level executives, gaining insights into decision-making processes and long-term vision development. In addition, I supported meeting documentation and project coordination, helping to ensure transparency and progress across teams.

Through this experience, I gained hands-on exposure to enterprise-level DX initiatives and developed a deeper understanding of business strategy and cross-functional project execution in high-stakes, uncertain environments.

松尾研究所にて、日本を代表する大手食品企業のDX推進プロジェクトに参画しました。AIエンジニアとしての知見を活かしつつも、主に戦略コンサルティング補佐のポジションとして従事しました。担当業務では、DXによる事業影響を定量化するための市場規模推定（フェルミ推定）や、市場・競合リサーチを通じた経営戦略立案の支援を行いました。また、経営陣向けの資料作成、週次で開催されるトップマネジメントとの会議への参加も担当し、戦略形成プロセスへの理解を深めました。

さらに、各種会議における議事録作成や情報共有を通じて、プロジェクトの意思決定プロセスの可視化と推進管理を支援しました。数千万円規模のDX案件に携わり、事業視点・組織視点の両面からAI技術の社会実装を考える経験を得ました。

株式会社インフラトップ
プログラミングスクール メンター（インターン）
2022年6月 - 2023年1月 (8ヶ月)

Worked as a mentor intern at DMM WebCamp, a programming school operated by Infratop. Provided remote learning support to students through curriculum-based Q&A, code review, and 1-on-1 mentoring. Gained hands-on experience in web development while improving communication, teaching, and empathetic mentoring skills to guide learners effectively.

Tech Stack & Skills:
Ruby / Ruby on Rails / HTML / CSS / Git / Instructional Support / Mentoring / Communication

DMMのプログラミングスクール「WebCamp」にて、受講生の学習支援を行うメンターインターンとして勤務しました。カリキュラムに基づく質問対応や課題レビュー、個別メンタリングを通じて、Web開発に関する技術力を

実践的に身につけるとともに、受講生の理解を深めるための説明力や共感をもってサポートする指導力も培いました。

主な使用技術・スキル：
Ruby / Ruby on Rails / HTML / CSS / Git / 教育・メンタリング / コミュニケーションスキル

学歴

東京理科大学
学士（工学）, 電気電子情報工学科 · (2021年3月 - 2025年3月)

東京理科大学
· (2021 - 2025)